

MATRIZ COMPARATIVA DE COSTOS

Ecosistema de Automatización IA - Selección y justificación del modelo

1. Criterio de comparación

Caso evaluado: clasificación de consultas comerciales y generación de un borrador breve para revisión humana.

Supuesto para la estimación: 1.000 consultas, con aproximadamente 1.000 tokens de entrada y 300 tokens de salida por consulta. Esto equivale a 1 millón de tokens de entrada y 0,3 millones de tokens de salida.

2. Precios de referencia

Modelo / modalidad	Entrada USD / 1M	Salida USD / 1M	Uso recomendado
DeepSeek V4 Flash	0,14 (cache miss)	0,28	Clasificación, extracción y respuestas comerciales breves.
GPT-5.6 Luna	0,20	1,20	Tareas generales de bajo costo y razonamiento liviano.
Claude Sonnet 5	2,00*	10,00*	Lectura más densa, análisis complejo y redacción de mayor exigencia.
Claude Sonnet 5 - Batch	1,00*	5,00*	Procesamiento masivo asíncrono cuando no se requiere respuesta inmediata.

* Precio promocional de Claude Sonnet 5 vigente hasta el 31/08/2026. La Batch API cobra 50% del precio estándar.

3. Costo estimado para 1.000 consultas

Modelo	Costo entrada	Costo salida	Costo total estimado	Índice vs DeepSeek
DeepSeek V4 Flash	USD 0,140	USD 0,084	USD 0,224	1,0x
GPT-5.6 Luna	USD 0,200	USD 0,360	USD 0,560	2,5x
Claude Sonnet 5	USD 2,000	USD 3,000	USD 5,000	22,3x
Claude Sonnet 5 - Batch	USD 1,000	USD 1,500	USD 2,500	11,2x

4. Selección por tarea

Tarea	Modelo recomendado	Justificación
Clasificar categoría y prioridad	DeepSeek V4 Flash	Muy bajo costo y salida JSON; suficiente para una tarea estructurada y repetitiva.
Generar borrador comercial breve	DeepSeek V4 Flash	Buena relación costo/rendimiento; la respuesta además pasa por HITL antes del envío.
Analizar documentos extensos o ambiguos	Claude Sonnet 5	Se reserva para tareas donde el mayor costo se justifica por complejidad y contexto.
Procesar grandes lotes sin urgencia	Batch API	Reduce el costo frente a procesamiento en tiempo real; adecuada para tareas masivas asíncronas.
Alternativa general de bajo costo	GPT-5.6 Luna	Opción económica con buen equilibrio para tareas generales, aunque más costosa que DeepSeek en este caso.

5. Decisión para el proyecto

Modelo elegido: DeepSeek. La automatización no necesita un modelo de máxima capacidad: la tarea consiste en interpretar un email, clasificarlo en categorías predefinidas, asignar prioridad, resumirlo y proponer una

respuesta corta. Además, el sistema incorpora Human-in-the-loop, por lo que ningún borrador se envía al cliente sin validación.

Conclusión económica: bajo el escenario estimado, DeepSeek V4 Flash tendría un costo aproximado de USD 0,224 por cada 1.000 consultas. GPT-5.6 Luna costaría alrededor de USD 0,560 y Claude Sonnet 5 alrededor de USD 5,00. Por lo tanto, DeepSeek ofrece la mejor relación costo/rendimiento para el flujo implementado.

6. Estrategia de optimización

- Limitar Max Tokens para evitar respuestas innecesariamente largas.
- Mantener el prompt conciso y estructurado.
- Usar salida JSON para evitar reintentos por formatos ambiguos.
- Aprovechar el caching cuando existan prefijos repetidos.
- Reservar modelos más costosos para casos excepcionales de alta complejidad.
- Utilizar procesamiento Batch únicamente cuando la tarea sea masiva y no requiera respuesta inmediata.

7. Fuentes de precios

- DeepSeek API Docs - Models & Pricing (consultado el 20/08/2026).
- OpenAI API - Pricing / GPT-5.6 Luna (consultado el 20/08/2026).
- Anthropic Claude Platform - Claude Sonnet 5 y Batch Processing (consultado el 20/08/2026).